

Universidad Autónoma de Santo Domingo
UASD

Facultad de Ciencias - Escuela de Informática.
División de Postgrado y Educación Permanente.

Maestría en Ciencia de Datos e Inteligencia Artificial.

Evaluación de impacto ético y auditoría de equidad de un DSS para la priorización de revisiones territoriales.

Presentado por:
Jose Miguel Maduro Valenzuela.

Catedrático:
Edwin Ramón José Nolasco.

Asignatura:
INF-8239 Ciencia de Datos II · Unidad 04 · Ejercicio U04.E07.

Santo Domingo de Guzmán, D.N.
Octubre de 2026.

Tabla de contenidos

Introducción. 4

1. Finalidad, interesados y proporcionalidad. 5

1.1. Planteamiento del problema. 5

1.2. Finalidad y decisión asistida. 5

1.3. Usuarios, población afectada y propietario. 5

1.4. Partes interesadas. 5

1.5. Proporcionalidad y alternativa no predictiva. 6

2. Registro de riesgos y NIST AI RMF. 6

2.1. Metodología de priorización. 6

2.2. Registro de riesgos. 7

2.3. Riesgos prioritarios. 7

2.4. Relación con el NIST AI RMF. 7

3. Auditoría global, por grupo e interseccional. 8

3.1. Datos y corte temporal. 8

3.2. Desempeño global y por grupo. 8

3.3. Análisis interseccional. 9

3.4. Incertidumbre y causalidad. 9

4. Mitigación, compromisos y decisión. 9

4.1. Comparación de alternativas. 9

4.2. Costo computacional (Green AI). 10

4.3. Opciones de decisión. 10

4.4. Decisión final. 10

5. Obligación legal, marco voluntario y recomendación ética. 11

5.1. Obligación legal. 11

5.2. Marco voluntario. 11

5.3. Recomendación ética. 11

6. Pruebas y reproducibilidad. 12

7. Declaración de uso de inteligencia artificial. 12

7.1. Herramienta y finalidad. 12

7.2. Uso por componente. 12

7.3. Prompts relevantes. 14

7.4. Errores detectados y correcciones. 14

7.5. Distribución de responsabilidades. 14

Conclusiones. 15

Referencias. 16

Anexos. 17

Anexo A. Repositorio y artefactos. 17

Anexo B. Comandos de reproducción. 17

Introducción.

Una evaluación de impacto no pregunta únicamente si un modelo funciona. Pregunta qué decisión modifica, quién obtiene beneficios, quién puede sufrir daño, qué alternativa menos invasiva existe y bajo qué condición debe detenerse el sistema. Este expediente integra las evidencias de los laboratorios U04.LAB11 (evaluación de impacto ético) y U04.LAB12 (auditoría de equidad con Fairlearn) aplicadas a un Sistema de Soporte a la Decisión (DSS) que ordena una cola de revisión técnica de casos territoriales.

El sistema evaluado, *Territorial Review DSS - Synthetic*, trabaja con un conjunto de datos **sintético** y didáctico de 640 casos. No representa personas, territorios ni estadísticas reales de la República Dominicana. Esto permite practicar la gobernanza de un DSS sin exponer a nadie, pero también limita las conclusiones: lo que se decide aquí es un ejercicio metodológico y no autoriza ningún uso real.

El documento se organiza así: el Capítulo 1 define la finalidad, los interesados y la proporcionalidad; el Capítulo 2 presenta el registro de riesgos y su relación con el NIST AI RMF; el Capítulo 3 expone la auditoría global, por grupo e interseccional; el Capítulo 4 analiza la mitigación, los compromisos y la decisión final; el Capítulo 5 diferencia la obligación legal, el marco voluntario y la recomendación ética; el Capítulo 6 resume las pruebas y la reproducibilidad; y el Capítulo 7 declara el uso de inteligencia artificial generativa. Al final se presentan las conclusiones, las referencias y los anexos.

Todas las cifras de este documento se leen de los artefactos generados en el repositorio (https://github.com/mudstart/INF8239_U04), que contiene los archivos editables, los scripts, las pruebas y los reportes. Cada afirmación remite al archivo que la respalda.

1. Finalidad, interesados y proporcionalidad.

1.1. Planteamiento del problema.

Un equipo técnico recibe casos territoriales que combinan riesgo de infraestructura, exposición e incidentes previos. Su capacidad de revisión es limitada, así que el orden en que atiende los casos determina cuánto espera cada uno. Un caso de alto riesgo que queda abajo en la cola sufre un retraso que puede tener consecuencias.

1.2. Finalidad y decisión asistida.

La finalidad del DSS es ordenar los casos para que el equipo revise primero los de mayor riesgo, sin reemplazar el juicio del analista. La decisión que asiste es acotada:

El DSS solo propone el orden de la cola semanal de revisión técnica. No decide intervención, elegibilidad ni asignación de recursos.

1.3. Usuarios, población afectada y propietario.

- **Usuarios:** analistas técnicos de revisión territorial y su coordinador de unidad.
- **Población afectada:** residentes de las zonas Norte, Sur, Este y Oeste, de los grupos protegidos G1 y G2 y de todas las franjas de edad. También son afectados indirectos los casos que bajan de prioridad y esperan más.
- **Propietario:** el Product Owner del DSS, que rinde cuentas ante el Institutional Owner y firma las decisiones GO, REVIEW o STOP.

1.4. Partes interesadas.

La Tabla 1 resume, para cada actor, su poder, el beneficio que obtiene, el daño que puede sufrir y su mecanismo de participación.

Actor	Poder	Beneficio	Daño posible	Participación
Persona afectada	Bajo	Revisión más temprana y consistente si su riesgo es alto	Que su caso baje por error o sesgo; estigmatización de su zona	Consulta comunitaria, aviso de uso del sistema y apelación
Operador	Medio	Ahorra tiempo de triaje	Sesgo de automatización; cargar con errores del modelo	Capacitación; reordenar justificando el cambio
Propietario institucional	Alto	Uso eficiente de la capacidad y trazabilidad	Daño reputacional y legal	Comité GO/REVIEW/STOP
Equipo de datos	Medio	Datos para demostrar valor frente a la línea base	Presión para desplegar sin evidencia	Auditoría del LAB12; puede recomendar STOP

Tabla 1. Partes interesadas. Fuente: student_inputs/stakeholders.csv.

1.5. Proporcionalidad y alternativa no predictiva.

Un modelo predictivo solo se justifica si mejora a una alternativa menos invasiva. Se definió como línea base una **regla no predictiva**: atender por orden de llegada (FIFO), adelantando los casos con tres o más incidentes previos o con exposición mayor a 0.7. La regla es transparente y auditable; si el modelo no la supera, se usa la regla.

También se definieron los límites del sistema:

- **Usos prohibidos:** intervención automática, decisión de elegibilidad, declarar emergencias, perfilar personas, usar el grupo protegido o la edad para priorizar y aplicar el sistema a poblaciones reales.
- **Condición de retiro:** recall menor a 0.68; brecha de recall o de FPR entre grupos mayor a 0.16; latencia mayor a 500 ms; un incidente de uso fuera de alcance; o que el piloto no supere la regla. Decide el Product Owner en un máximo de 48 horas.
- **Apelación:** cualquier persona afectada o un analista puede pedir que se revise la prioridad de un caso. Responde un revisor que no generó la recomendación, en un máximo de 5 días hábiles.

Fuente: student_inputs/lab11_impact.yml.

2. Registro de riesgos y NIST AI RMF.

2.1. Metodología de priorización.

Se registraron nueve riesgos, cada uno con su escenario, la población afectada, la probabilidad y el impacto en una escala de 1 a 4, el control, el responsable, la evidencia esperada y el riesgo residual. La prioridad se calcula como probabilidad por impacto. Esa puntuación ordena la atención, pero no convierte el daño humano en una verdad matemática: cada escenario se revisó por separado.

2.2. Registro de riesgos.

ID	Escenario	P × I	Responsable	Residual
R01	El modelo tiene menor recall en un grupo protegido o una zona y retrasa la revisión de casos de alto riesgo de ese grupo	3 × 4 = 12	Data Scientist	Alto
R02	Los analistas aceptan el orden del modelo sin revisarlo (sesgo de automatización) y no corrigen sus errores	3 × 3 = 9	Product Owner	Medio
R04	Hay deriva temporal: la relación entre exposición e incidentes cambia y el modelo pierde recall sin que nadie lo note	3 × 3 = 9	ML Engineer	Medio
R06	Las features proxy (zona e índice de infraestructura) reproducen desigualdades históricas y estigmatizan zonas con menos inversión	3 × 3 = 9	Data Scientist	Medio
R03	El sistema se usa para decidir elegibilidad o intervención automática (uso fuera de alcance)	2 × 4 = 8	Institutional Owner	Medio
R07	Nadie atiende las apelaciones a tiempo y las personas no tienen una vía real para impugnar la prioridad	2 × 4 = 8	Product Owner	Medio
R09	Las etiquetas (target) del dataset sintético no representan el daño real y el sistema optimiza un objetivo equivocado	2 × 3 = 6	Data Engineer	Medio
R05	Se filtran o reidentifican personas al combinar el caso con datos externos (identificadores directos en el dataset)	1 × 4 = 4	Data Engineer	Bajo
R08	Un fallo técnico (latencia mayor a 500 ms o un artefacto corrupto) detiene la cola y retrasa todas las revisiones	2 × 2 = 4	ML Engineer	Bajo

Tabla 2. Registro de riesgos ordenado por prioridad. Fuente: reports/lab11/risk_register_scored.csv.

2.3. Riesgos prioritarios.

- **R01 (prioridad 12, residual alto):** menor recall en un grupo protegido o una zona. Quitar *protected_group* del modelo no garantiza equidad, porque *zone* e *infrastructure_score* pueden funcionar como proxies. Es el riesgo que la auditoría del Capítulo 3 confirmó.
- **R02 (prioridad 9):** sesgo de automatización. Un sistema de apoyo deja de serlo si el analista acepta el orden sin revisarlo.
- **R04 (prioridad 9):** deriva temporal. El modelo puede perder recall sin que nadie lo note; el control es el monitoreo mensual con retiro a la regla.
- **R06 (prioridad 9, empate):** proxies territoriales. El orden automático lo deja cuarto, pero se trata con la misma urgencia porque afecta al actor con menos poder y amplifica R01.

2.4. Relación con el NIST AI RMF.

Función	Evidencia en el repositorio
GOVERN	Responsables por rol, matriz RACI (student_inputs/raci.csv) y usos prohibidos (configs/governance.yml).
MAP	Propósito, interesados y nueve riesgos documentados (reports/lab11/risk_register_scored.csv).
MEASURE	Auditoría global, por grupo e interseccional (reports/lab12/AUDIT_REPORT.md).
MANAGE	Decisión LIMITAR, condición de retiro y apelación (reports/lab11/DECISION_RECORD.md).

Tabla 3. Funciones del NIST AI RMF. Resumen generado en reports/lab11/rmf_summary.json.

Un archivo existente no prueba que un control sea eficaz. Los controles de R02 y R07 (registro de reordenamientos y de apelaciones) están definidos, pero todavía no tienen evidencia operativa: solo podrán medirse durante el piloto.

3. Auditoría global, por grupo e interseccional.

3.1. Datos y corte temporal.

El conjunto tiene 640 casos, con 55.2 % de positivos (G1 = 396 y G2 = 244). Se usó un corte temporal: el modelo se entrena con los casos hasta el 24 de septiembre de 2026 y se evalúa con los posteriores (n = 160; G1 = 101 y G2 = 59). Así no se usa el futuro para evaluar el pasado.

La variable *protected_group* no entra al modelo y se conserva solo para auditar. En cambio, *age_band*, que la configuración declara sensible, **sí** entra como variable predictora. Aunque el objetivo está casi balanceado, accuracy no basta: promedia los grupos y no distingue entre perder un caso de riesgo y dar una alerta innecesaria.

3.2. Desempeño global y por grupo.

Se compararon tres alternativas: la regla no predictiva, una regresión logística y un árbol de decisión de profundidad 5 (Tabla 4).

Modelo	Accuracy	Recall	FPR	Selec.	Brecha recall (IC95)	Brecha FPR	Recall G1	Recall G2
Regla no predictiva	0.675	0.837	0.544	0.713	0.131 [0.010, 0.290]	0.106	0.898	0.767
Regresión logística	0.719	0.717	0.279	0.531	0.138 [0.009, 0.322]	0.125	0.653	0.791
Árbol de decisión	0.706	0.717	0.309	0.544	0.181 [0.023, 0.361]	0.168	0.633	0.814

Tabla 4. Métricas en el conjunto de prueba. El IC95 sale de un bootstrap con 1000 remuestreos (semilla 42). Fuente: reports/lab12/model_comparison.csv.

La regresión logística pasa las puertas automáticas del sistema: recall global de 0.717, brecha de recall de 0.138 y brecha de FPR de 0.125. Sin embargo, el recall del grupo G1 es

0.653, por debajo del mínimo de 0.68. Las puertas solo miran el recall global, así que el promedio oculta una falla localizada en el grupo más grande.

3.3. Análisis interseccional.

Se combinaron el grupo protegido y la franja de edad. Como el recall se calcula solo con los casos positivos, una intersección se interpreta únicamente si tiene al menos 20 casos y 10 positivos. Este mínimo es un criterio propio, porque el proyecto base no documentaba ninguno.

Intersección	Casos	Positivos	¿Se interpreta?	Recall	FPR
G1 · 18-29	18	4	No	(0.750)	(0.143)
G1 · 30-44	24	16	Sí	0.562	0.125
G1 · 45-59	35	17	Sí	0.588	0.389
G1 · 60+	24	12	Sí	0.833	0.250
G2 · 18-29	11	8	No	(0.875)	(0.000)
G2 · 30-44	14	12	No	(0.667)	(0.500)
G2 · 45-59	8	6	No	(1.000)	(0.000)
G2 · 60+	26	17	Sí	0.765	0.556

Tabla 5. Regresión logística por intersección. Los valores entre paréntesis no se interpretan. Fuente: reports/lab12/intersectional_support.csv.

Dos patrones tienen soporte suficiente. La falla de G1 se concentra entre los 30 y los 59 años, con recall menor a 0.60. Y el grupo G2 de 60 años o más recibe más alertas innecesarias (FPR de 0.556), lo que significa carga de revisión pero no intervención. Los grupos pequeños se muestran para no ocultarlos, pero no se sacan conclusiones de ellos.

3.4. Incertidumbre y causalidad.

Una brecha observada no prueba, por sí sola, discriminación causal. El intervalo de confianza de la brecha de recall de la logística va de 0.009 a 0.322: no se sabe si la brecha real es casi nula o el doble de la tolerancia. Además, la brecha puede venir de diferencias entre los grupos en zona, edad o incidentes previos, o de que el objetivo mida peor el riesgo en un grupo. Es una señal que obliga a investigar con un análisis de proxies y con la validación de expertos y comunidades.

4. Mitigación, compromisos y decisión.

4.1. Comparación de alternativas.

- **Logística frente a árbol:** el árbol no gana utilidad (mismo recall global, 0.717, y menor accuracy), no pasa las brechas (recall 0.181 y FPR 0.168) y pesa más del doble. Más complejidad sin beneficio: se descarta.

- **Logística frente a regla:** la regla detecta más positivos (recall 0.837 y 0.898 en G1), pero marca al 71 % de los casos con un FPR de 0.544. Con capacidad limitada, marcar a casi tres de cada cuatro casos ya no ordena la cola. Es un compromiso y no una victoria: la regla protege mejor a G1 frente al daño priorizado, y la logística usa mejor la capacidad.

4.2. Costo computacional (Green AI).

Ambos modelos entrenan en unos 0.06 segundos, ocupan 3.6 KB (logística) y 7.9 KB (árbol) y predicen en unos 0.02 ms por caso, muy por debajo de los límites de 500 ms y 1024 KB. Aun así, se prefiere la opción suficiente: la logística da la misma utilidad que el árbol con la mitad del tamaño y es más interpretable para la revisión y la apelación.

4.3. Opciones de decisión.

Opción	¿Se elige?	Motivo
Desplegar	No	El recall de G1 (0.653) está bajo la tolerancia y el IC de la brecha supera 0.16.
Modificar	Como condición	Ajustar el umbral por grupo o conseguir más datos, validado antes de cualquier GO.
Limitar	Sí	Piloto en modo sombra junto a la regla, con revisión humana de cada caso y monitoreo mensual de G1 de 30 a 59 años.
No utilizar	No por ahora	Es razonable si se prioriza el recall de G1, que la regla ya cubre mejor. Se reevalúa al terminar el piloto.

Tabla 6. Opciones de decisión evaluadas.

4.4. Decisión final.

LIMITAR. No se despliega el árbol. La regresión logística solo pasa a un piloto en modo sombra: la regla no predictiva sigue ordenando la cola y un analista revisa cada caso.

En el LAB11 la decisión fue **REVISAR**, porque todavía no había métricas. La auditoría del LAB12 convirtió esa incertidumbre en evidencia y la decisión pasó a **LIMITAR**. Para pasar a GO se requiere que el recall de G1 llegue a 0.68, que la brecha de FPR se mantenga en 0.16 o menos y que el intervalo de la brecha de recall ya no supere la tolerancia. El responsable es el Product Owner, con el apoyo del Data Scientist, y la condición de retiro de la sección 1.5 sigue vigente. Fuentes: student_inputs/lab12_decision.yml y reports/lab11/DECISION_RECORD.md.

5. Obligación legal, marco voluntario y recomendación ética.

Se distinguen tres niveles porque tienen consecuencias distintas: una obligación legal se puede exigir y sancionar; un marco voluntario es una buena práctica que se adopta por decisión institucional; y una recomendación ética es un criterio propio del proyecto que hay que justificar.

5.1. Obligación legal.

En la República Dominicana aplican la Constitución, en lo relativo a la igualdad (art. 39), la intimidad (art. 44) y el hábeas data (art. 70), y la Ley 172-13 sobre Protección Integral de los Datos Personales. El proyecto las atiende al rechazar identificadores directos (lo verifica *tests/test_privacy.py*), acotar la finalidad y ofrecer una vía de apelación. A octubre de 2026 no existe una ley de inteligencia artificial aprobada, solo proyectos en el Congreso, y la Ley 172-13 no regula de forma específica las decisiones automatizadas. Como los datos son sintéticos, la ley aplicaría en pleno solo si el sistema se usara con datos reales, lo que exigiría una nueva evaluación de impacto.

5.2. Marco voluntario.

El NIST AI RMF 1.0 estructura el expediente con sus funciones GOVERN, MAP, MEASURE y MANAGE. La Recomendación de la OECD sobre IA aporta los principios de equidad, transparencia, robustez y rendición de cuentas; la República Dominicana no es miembro de la OECD, así que la recomendación es una referencia. Fairlearn es un método técnico de medición, y la Estrategia Nacional de IA coordinada por la OGTIC es una política pública, no una ley.

5.3. Recomendación ética.

Ninguna norma exige las siguientes decisiones; son criterios del proyecto que deben defenderse: la tolerancia de 0.16 en las brechas, el recall mínimo de 0.68 en cada grupo y no solo en el global, la regla no predictiva como línea base, el soporte mínimo para las intersecciones, la apelación con revisor independiente y la decisión de LIMITAR en lugar de aceptar el GO automático.

Nivel	¿Exigible?	Ejemplo en este proyecto
Obligación legal	Sí	Sin identificadores directos; finalidad acotada; hábeas data y apelación.
Marco voluntario	No, se adopta	Funciones del NIST AI RMF; principios de la OECD.
Recomendación ética	No, se justifica	Umbrales de 0.16 y 0.68 por grupo; regla base; decisión LIMITAR.

Tabla 7. Síntesis normativa. Análisis completo en docs/NORMATIVE_ANALYSIS.md.

6. Pruebas y reproducibilidad.

El proyecto se gestiona con *uv* para aislar las dependencias y con Git para registrar el avance. La Tabla 8 resume la evidencia de verificación.

Evidencia	Resultado
uv run pytest -q	10 pruebas superadas: impacto, privacidad, equidad, modelo, datos, gobernanza y aplicación.
scripts/check_environment.py	dataset_status: valid (640 filas y 9 columnas).
scripts/validate_lab12_decision.py	decision_status: documented.
Historial de Git	chore: initialize Unit 04 project; docs: complete ethical impact assessment; feat: add group fairness audit.

Tabla 8. Pruebas y validaciones. Los comandos para reproducir los resultados están en el Anexo B.

7. Declaración de uso de inteligencia artificial.

7.1. Herramienta y finalidad.

Se usó Claude, asistente de IA generativa de Anthropic (modelo Claude Opus 5.5), el 21 de octubre de 2026, en la aplicación Claude. Se usó para revisar el cumplimiento de los requisitos, redactar borradores, ejecutar los scripts y las pruebas, corregir un error del script base y redactar el análisis normativo. La IA no decidió los valores del análisis: las métricas provienen de ejecutar el código y se pueden reproducir.

7.2. Uso por componente.

La Tabla 9 detalla el uso de IA en cada componente, con el nivel de dependencia, los riesgos asociados y los mecanismos de mitigación.

Componente del trabajo	Uso de IA	Intervención del autor	Nivel de dependencia	Riesgos asociados	Mecanismos de mitigación
Ficha de propósito e interesados	Primer borrador de los campos	Revisión y ajuste al caso	Alto	Texto genérico o poco contextual	Lectura crítica y ajuste
Registro de riesgos	Borrador de los nueve riesgos	Revisión de escenarios, valores y responsables	Alto	Riesgos no verificables	Exigir responsable y evidencia por riesgo
Auditoría de equidad	Ejecutar scripts y un script de comparación	Interpretación y decisión final	Medio	Afirmaciones sin evidencia	Métricas leídas solo de archivos generados
Corrección técnica	Detectar y corregir el error del script base	Validar que el script y las pruebas corren	Medio	Errores en código sugerido	Pruebas automáticas
Redacción del documento	Estructura y redacción	Revisión final y control de estilo	Alto	Imprecisiones o ambigüedades	Revisión crítica y edición
Commits y publicación	No utilizado	Commits y push hechos por el autor	Nulo	—	Control completo por el autor

Tabla 9. Uso de IA por componente. Detalle en docs/AI_USE_DECLARATION.md.

7.3. Prompts relevantes.

La Tabla 10 resume los prompts principales, en el orden en que se usaron, y el resultado que produjo cada uno.

Fase	Prompt (resumido)	Resultado
LAB11	Preparar borradores de la evaluación de impacto a partir del enunciado	Ficha, interesados, riesgos y registro de decisión
E07	Contrastar el trabajo con el mandato y la rúbrica	Lista de pendientes
LAB12	Ejecutar la auditoría de equidad y preparar la decisión	Métricas, comparación de modelos y borrador de decisión
Documento	Integrar las evidencias en un PDF con formato académico	Este documento

Tabla 10. Prompts relevantes.

7.4. Errores detectados y correcciones.

- El script base del LAB11 no se podía ejecutar por un error de sintaxis; se corrigió.
- La IA afirmó por error que *age_band* estaba excluida del modelo. Al revisar el código en el LAB12 se comprobó que sí entra, y se corrigió en el registro de riesgos, el registro de decisión y el informe de auditoría.
- La puerta automática daba GO por el recall global; la revisión por grupo mostró la falla de G1 y no se aceptó.
- El proyecto no documentaba un soporte mínimo para las intersecciones; se fijó uno y se declaró como criterio propio.

7.5. Distribución de responsabilidades.

La definición de los valores del análisis, la interpretación normativa, la decisión final y la publicación en el repositorio corresponden al autor, que responde por cada elemento de este expediente. La IA actuó como herramienta de apoyo bajo revisión crítica, y su uso se declara aquí y en el repositorio para que sea trazable.

Conclusiones.

El ejercicio mostró que un sistema puede pasar sus puertas automáticas y aun así no estar listo para desplegarse. La regresión logística cumple los umbrales globales, pero falla en el grupo G1, y esa falla se concentra entre los 30 y los 59 años. Sin la desagregación por grupo e intersección, el promedio la habría ocultado.

La evaluación de impacto previa fue decisiva para interpretar la auditoría. Definir antes cuál era el daño prioritario, el falso negativo, permitió elegir el recall por grupo como métrica principal y no conformarse con la accuracy. Del mismo modo, contar con una alternativa no predictiva convirtió la comparación en un compromiso explícito: la regla protege mejor a G1, mientras que el modelo usa mejor la capacidad de revisión.

La decisión final, LIMITAR, reconoce ese compromiso y la incertidumbre de una muestra pequeña. El modelo solo se observa en modo sombra, con revisión humana de cada caso, condiciones claras para pasar a GO y una condición de retiro definida. Separar lo que exige la ley, lo que propone un marco voluntario y lo que es un criterio ético propio hace visible qué partes de esta decisión hay que defender con argumentos y no solo con normas.

Por último, los datos son sintéticos. Las conclusiones valen como ejercicio metodológico; aplicar el sistema a casos reales requeriría una nueva evaluación de impacto, validar el objetivo con expertos y consultar a las comunidades afectadas.

Referencias.

Bird, S., Dudík, M., Edgar, R., Horn, B., Lutz, R., Milan, V., Sameki, M., Wallach, H., & Walker, K. (2020). *Fairlearn: A toolkit for assessing and improving fairness in AI* (Technical Report MSR-TR-2020-32). Microsoft.

Fairlearn Contributors. (s. f.). *Performing a fairness assessment*. Documentación oficial de Fairlearn. https://fairlearn.org

National Institute of Standards and Technology. (2023). *Artificial Intelligence Risk Management Framework (AI RMF 1.0)* (NIST AI 100-1). https://doi.org/10.6028/NIST.AI.100-1

OECD. (2019). *Recommendation of the Council on Artificial Intelligence* (OECD/LEGAL/0449; actualizada en 2024). https://doi.org/10.1787/cc2e1d3e-en

República Dominicana. (2013). *Ley No. 172-13 sobre Protección Integral de los Datos Personales*. Gaceta Oficial.

República Dominicana. (2015). *Constitución de la República Dominicana*. Gaceta Oficial.

Anexos.

Anexo A. Repositorio y artefactos.

El repositorio contiene los artefactos editables, las pruebas y las evidencias de este expediente:

Repositorio: https://github.com/mudstart/INF8239_U04

Artefacto	Contenido
student_inputs/lab11_impact.yml	Ficha de propósito, alternativa no predictiva, retiro y apelación
student_inputs/stakeholders.csv	Partes interesadas
student_inputs/risk_register.csv	Registro de riesgos editable
student_inputs/lab12_decision.yml	Decisión de la auditoría
reports/lab11/	Riesgos puntuados, resumen NIST y registro de decisión
reports/lab12/	Métricas por modelo, comparación, soporte interseccional e informe de auditoría
docs/NORMATIVE_ANALYSIS.md	Análisis normativo
docs/AI_USE_DECLARATION.md	Declaración de uso de IA
scripts/ y tests/	Código de generación y pruebas automáticas

Tabla 11. Artefactos del repositorio.

Anexo B. Comandos de reproducción.

Desde la carpeta del proyecto, los resultados se reproducen con los siguientes comandos:

Paso	Comando
1	uv sync --frozen
2	uv run python scripts/check_environment.py
3	uv run python scripts/lab11_impact.py
4	uv run python scripts/lab12_audit.py --model logistic
5	uv run python scripts/lab12_audit.py --model tree
6	uv run python scripts/lab12_compare.py
7	uv run python scripts/validate_lab12_decision.py
8	uv run pytest -q

Tabla 12. Comandos de reproducción.